

Fallstudie – Titanic Survival Challenge

Die Fallstudie kann in **Gruppen von bis zu drei Personen** abgeschlossen werden und wird für alle Gruppen am gleichen Datensatz (train und test Datensatz im Moodlekurs) ausgeführt. Die Aufgabe besteht darin, vorherzusagen, welche Passagiere das Unglück auf der Titanic überleben.

Folgende Aufgabenstellungen sollen erfüllt werden:

- Beschreiben Sie die vorliegenden Daten in verbaler und visueller Form. Dazu ist es notwendig einige explorative Analyseschritte vorzunehmen.
- Untersuchen Sie den Datensatz auf ggfs. notwendige Vorverarbeitungsschritte und dokumentieren Sie diese.
- Wenden Sie mindestens drei verschiedene (müssen nicht aus der LV sein) Machine Learning Ansätze an und beschreiben Sie Ihr Vorgehen.
- Ein Ergebnis der Fallstudie ist eine Aussage darüber, welche Personen im Testdatensatz überleben und welche nicht.

Die Beurteilungsgrundlage für die Fallstudie bildet allerdings nicht die Qualität des Ergebnisses, sondern die Qualität Ihrer Präsentation. Dazu zählt:

- Sind Analyseschritte und vorangegangene Überlegungen nachvollziehbar argumentiert? z.B. Ein K-Means Clustering wurde als explorative Methode eingesetzt, um Informationen über mögliche Segmentierungen innerhalb der Passagiergruppen zu erhalten.
- Sind Ergebnisse und Güte der Modelle nachvollziehbar dokumentiert? Siehe dazu Modell Performance in den LV Unterlagen.
- Sind die Hyperparameter der Modelle nachvollziehbar gewählt?
- Sind die Ergebnisse und Erkenntnisse aus den Modellen ansprechend präsentiert?

Abzugeben sind ein zusammenfassendes Dokument mit Ihren Begründungen und Überlegungen sowie Ergebnissen (**ca. 3-5 Seiten, inkl. Screenshots**) und das jeweilige Code-File. Die Aufgaben können in einer Programmiersprache Ihrer Wahl gelöst werden.

Die Fallstudie ist bis **zum 17.10.2026 LV-Beginn** fertigzustellen und wird an diesem Tag von jeder Gruppe präsentiert. Die Präsentationszeit beträgt **maximal 15 Minuten** (anschließend ca. 10 Minuten Diskussion) und die Präsentationsform kann frei gewählt werden. Für die Beurteilung wird ausschließlich Präsentation herangezogen.

Der Titanic Datensatz ist Grundlage für zahlreiche Challenges und Tutorials, Sie haben natürlich die Möglichkeit von bereits vorangegangenen Bearbeitungen zu profitieren. Einige gelungene Versuche finden Sie hier: <https://www.kaggle.com/competitions/titanic> , <https://www.kaggle.com/code/nikitakudriashov/top-1-titanic-solution>

Zur Ausführung der Modelle und Analyseschritte können generative Modelle herangezogen werden, bitte kennzeichnen Sie jene Stellen mit einer Fußnote und dem benutzten Prompt.